Deliverable 2 - Estatística Multivariada

Indicadores organizacionais de maturidade no uso de IA

DAMA Intelligence - Ana Luiza Proença, Gustavo Gomes, Kaique Lira e Ricardo Matteo

03/11/2026

Objetivo

No Deliverable 1 testamos duas hipóteses usando correlações e boxplots:

- **H1:** treinamento aumenta o uso de IA (confirmada, mas com efeito fraco, r = 0,11);
- **H2:** treinamento reduz incidentes de segurança (não confirmada, r = -0,02).

A conclusão do D1 pedia uma análise mais completa, controlando por área, cargo e exposição às ferramentas. Neste trabalho queremos responder três perguntas:

1. Os indicadores de IA de cada departamento podem ser resumidos em poucas dimensões?
2. Existem grupos de departamentos com perfis parecidos?
3. H1 e H2 continuam valendo quando colocamos variáveis de controle?

Para isso usamos segmentação (agrupamento hierárquico, k-means e k-means++) e regressão logística binária.

Pacotes

```
library(tidyverse)
library(knitr)
library(corrplot)
library(cluster)
library(pheatmap)
library(ClusterR)
library(mclust)
library(pROC)
library(ggrepel)
library(writexl)
```

Parâmetros da análise

```
# Pasta com os CSVs do projeto (ajuste se o Rmd estiver em outro lugar)
pasta_dados = "../../Deliverable1/machine-learning-ia/Data/csv/"

meses = paste0("2026-0", 1:7)  # janeiro a julho de 2026
cambio = 5.50                  # premissa: R$ por US$
tamanho_minimo = 5             # mínimo de colaboradores ativos no departamento
semente = 123

# Funções para escrever números com vírgula no texto
```

```r
num = function(x, precisao = 0.01) {
  scales::number(x, accuracy = precisao, decimal.mark = ",")
}

valor_p = function(p) {
  if_else(p < 0.001, "p < 0,001", paste("p =", num(p, 0.001)))
}
```

Leitura das bases

```r
funcionarios = read_csv(paste0(pasta_dados, "employees.csv"))
departamentos = read_csv(paste0(pasta_dados, "departments.csv"))
empresas = read_csv(paste0(pasta_dados, "companies.csv"))
treinamentos = read_csv(paste0(pasta_dados, "training_records.csv"))
licencas = read_csv(paste0(pasta_dados, "ai_licenses.csv"))
seguranca = read_csv(paste0(pasta_dados, "security_events.csv"))
faturamento = read_csv(paste0(pasta_dados, "ai_billing.csv"))
orcamentos = read_csv(paste0(pasta_dados, "ai_budgets.csv"))
uso = read_csv(paste0(pasta_dados, "ai_usage_logs.csv"))

# Só o período analisado
uso = uso %>%
  mutate(mes = format(timestamp, "%Y-%m")) %>%
  filter(mes %in% meses)

uso_sucesso = uso %>%
  filter(request_status == "success")
```

Construção dos indicadores

A unidade de análise é o **departamento**, porque é nele que a empresa decide licenças, treinamentos e orçamento. Primeiro resumimos cada base por colaborador.

```r
resumo_uso = uso_sucesso %>%
  group_by(employee_id) %>%
  summarise(
    req = sum(request_count),
    tok = sum(input_tokens + output_tokens),
    meses_uso = n_distinct(mes),
    ferr = n_distinct(ai_tool_id)
  )

resumo_tentativas = uso %>%
  group_by(employee_id) %>%
  summarise(req_total = sum(request_count))

resumo_cursos = treinamentos %>%
  filter(completion_status == "Concluido") %>%
  group_by(employee_id) %>%
  summarise(
    cursos = n(),
    nota = mean(score),
```

```
    horas = sum(duration_hours)
  )

resumo_incidentes = seguranca %>%
  count(employee_id, name = "inc")

pares_usados = paste(uso_sucesso$employee_id, uso_sucesso$ai_tool_id)

resumo_licencas = licencas %>%
  filter(license_status == "Ativa") %>%
  mutate(usada = paste(employee_id, ai_tool_id) %in% pares_usados) %>%
  group_by(employee_id) %>%
  summarise(
    lic = n(),
    lic_usadas = sum(usada)
  )
```

Para reunir tudo em uma tabela só, empilhamos o cadastro e os resumos e somamos por colaborador. A primeira linha de cada colaborador vem do cadastro, e quem não aparece em um resumo fica com soma zero.

```
todos_colaboradores = bind_rows(
  funcionarios,
  resumo_uso,
  resumo_tentativas,
  resumo_cursos,
  resumo_incidentes,
  resumo_licencas
) %>%
  group_by(employee_id) %>%
  summarise(
    across(
      c(company_id, department_id, seniority, hire_date, active),
      ~ .x[1]
    ),
    across(
      c(req, tok, meses_uso, ferr, req_total, cursos, horas, inc,
        lic, lic_usadas),
      ~ sum(.x, na.rm = TRUE)
    ),
    nota = mean(nota, na.rm = TRUE)
  )

# Só colaboradores ativos
colaboradores = todos_colaboradores %>%
  filter(active == TRUE)
```

Depois calculamos as licenças ociosas, o gasto e o orçamento.

```
ociosidade = todos_colaboradores %>%
  group_by(department_id) %>%
  summarise(
    lic_ativas = sum(lic),
    lic_usadas = sum(lic_usadas)
  )
```

```r
gasto = faturamento %>%
  filter(billing_month %in% meses) %>%
  mutate(
    custo_brl = if_else(currency == "USD", total_cost * cambio, total_cost),
    department_id = str_remove(cost_center, "CC-")
  ) %>%
  group_by(department_id) %>%
  summarise(gasto = sum(custo_brl) / length(meses))

orcado = orcamentos %>%
  filter(year == 2026, month <= 7) %>%
  mutate(department_id = str_remove(cost_center, "CC-")) %>%
  group_by(department_id) %>%
  summarise(orcado = mean(budget_amount))

# Empilhamos empresas e departamentos para levar o nome e o setor
# da empresa até cada departamento
cadastro_departamentos = bind_rows(empresas, departamentos) %>%
  group_by(company_id) %>%
  mutate(
    across(
      c(company_name, industry),
      ~ .x[1]
    )
  ) %>%
  ungroup() %>%
  filter(!is.na(department_id))
```

Agora calculamos os indicadores por departamento e empilhamos com o restante, do mesmo jeito.

```r
indicadores_ativos = colaboradores %>%
  group_by(department_id) %>%
  summarise(
    n = n(),
    adocao = mean(req > 0),
    intensidade = log(1 + sum(req) / n() / length(meses)),
    regularidade = sum(meses_uso) / sum(req > 0) / length(meses),
    amplitude = sum(ferr) / sum(req > 0),
    sucesso = sum(req) / sum(req_total),
    tokens_req = log(sum(tok) / sum(req)),
    capacitacao = mean(cursos > 0),
    horas = mean(horas),
    nota = mean(nota, na.rm = TRUE),
    licencas = mean(lic),
    incidentes = 100 * sum(inc) / n()
  )

indicadores_todos = bind_rows(
  cadastro_departamentos,
  indicadores_ativos,
  ociosidade,
  gasto,
  orcado
) %>%
```

```r
  group_by(department_id) %>%
  summarise(
    across(
      c(company_id, department_name, company_name, industry),
      ~ .x[1]
    ),
    across(
      c(n, adocao, intensidade, regularidade, amplitude, sucesso,
        tokens_req, capacitacao, horas, nota, licencas, incidentes,
        lic_ativas, lic_usadas, gasto, orcado),
      ~ sum(.x, na.rm = TRUE)
    )
  ) %>%
  filter(n > 0) %>%  # só departamentos com colaboradores ativos
  mutate(
    nota = if_else(capacitacao > 0, nota, NA_real_),
    ociosas = if_else(lic_ativas > 0, 1 - lic_usadas / lic_ativas, 0),
    custo_colab = log(gasto / n),
    execucao = gasto / orcado,
    setor = str_remove(industry, " / Desenvolvimento de Software")
  )

# Departamentos pequenos ficam de fora, porque uma pessoa muda muito a proporção
indicadores = indicadores_todos %>%
  filter(n >= tamanho_minimo)

# Sem nenhum uso de IA: tratados à parte
sem_uso = indicadores %>%
  filter(adocao == 0)

dados = indicadores %>%
  filter(adocao > 0)
```

Dos 154 departamentos, 110 têm pelo menos 5 colaboradores ativos. Desses, 4 não usaram IA no período. Sem uso não dá para calcular intensidade nem tokens por requisição, então eles ficam fora da segmentação e entram no fim do ranking. Sobram **106 departamentos**.

Indicador	O que mede	Dimensão esperada
`adocao`	% de colaboradores que usaram IA	Uso
`intensidade`	log(1 + requisições por colaborador por mês)	Uso
`regularidade`	fração dos 7 meses em que os usuários usaram IA	Uso
`amplitude`	média de ferramentas diferentes por usuário	Uso
`ociosas`	% de licenças ativas sem nenhum uso	Uso (invertido)
`tokens_req`	log(tokens por requisição)	Uso (invertido)
`capacitacao`	% de colaboradores com curso concluído	Capacitação
`horas`	horas de curso por colaborador	Capacitação
`nota`	nota média nos cursos concluídos	Capacitação
`custo_colab`	log(gasto mensal por colaborador, em R$)	Investimento
`licencas`	licenças ativas por colaborador	Investimento
`execucao`	gasto mensal / orçamento mensal	Investimento
`sucesso`	% de requisições concluídas com sucesso	Qualidade técnica
`incidentes`	eventos de segurança por 100 colaboradores	Risco

Análise descritiva

```
variaveis_indicadores = c(
  "adocao", "intensidade", "regularidade", "amplitude", "ociosas",
  "tokens_req", "capacitacao", "horas", "nota", "custo_colab",
  "licencas", "execucao", "sucesso", "incidentes"
)

resumo = dados %>%
  dplyr::select(all_of(variaveis_indicadores)) %>%
  summarise(
    across(
      everything(),
      list(
        Media = ~ mean(.x, na.rm = TRUE),
        DP = ~ sd(.x, na.rm = TRUE),
        CV = ~ 100 * sd(.x, na.rm = TRUE) / mean(.x, na.rm = TRUE)
      ),
      .names = "{.col}_{.fn}"
    )
  ) %>%
  pivot_longer(
    cols = everything(),
    names_to = c("Variavel", "Medida"),
    names_pattern = "(.*)_(Media|DP|CV)",
    values_to = "Valor"
  ) %>%
  pivot_wider(names_from = Medida, values_from = Valor)

kable(
  resumo,
  digits = 2,
  col.names = c("Variável", "Média", "Desvio-padrão", "CV (%)"),
  caption = "Medidas descritivas nas unidades originais"
)
```

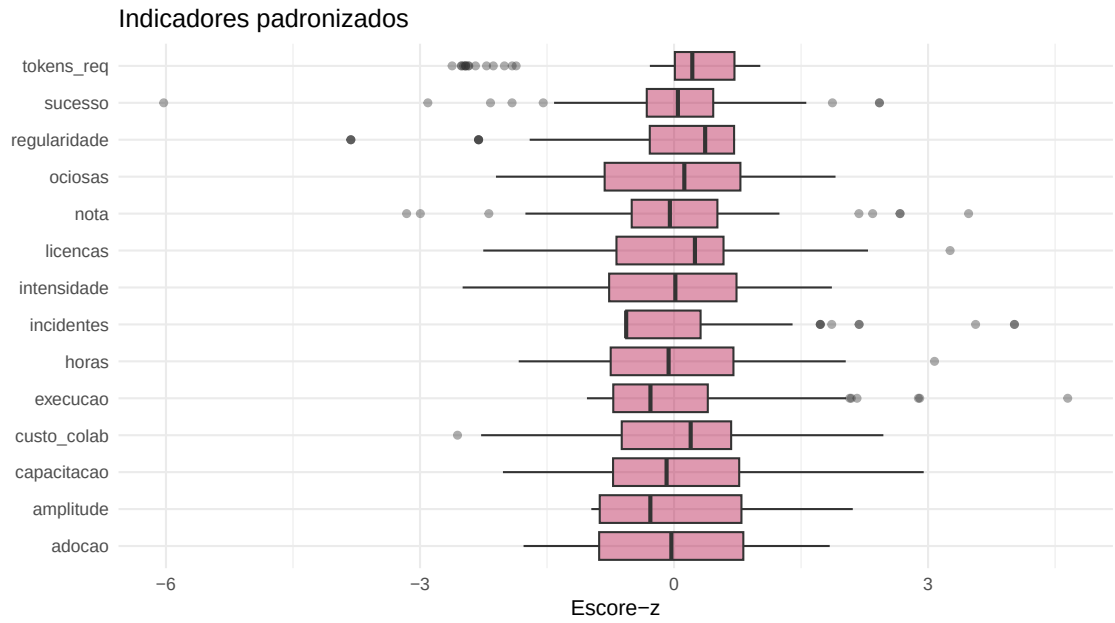
Table 2: Medidas descritivas nas unidades originais

Variável	Média	Desvio-padrão	CV (%)
adocao	0.52	0.26	49.92
intensidade	4.72	1.67	35.40
regularidade	0.93	0.09	10.15
amplitude	3.47	1.67	48.24
ociosas	0.52	0.25	47.55
tokens_req	7.13	0.44	6.24
capacitacao	0.35	0.17	49.49
horas	1.01	0.55	54.51
nota	76.51	6.18	8.07
custo_colab	5.32	0.37	6.90
licencas	1.64	0.45	27.19
execucao	0.83	0.67	81.29
sucesso	0.95	0.02	2.10
incidentes	4.11	7.27	176.90

Os indicadores estão em escalas bem diferentes (proporções, horas, logaritmos). Por isso vamos precisar padronizar antes de calcular distâncias. O `incidentes` é o mais disperso, com CV de 177%, porque a maioria dos departamentos quase não tem eventos.

```
dados_z_grafico = dados %>%
  select(all_of(variaveis_indicadores)) %>%
  mutate(
    across(
      everything(),
      ~ as.numeric(scale(.x))
    )
  ) %>%
  pivot_longer(
    cols = everything(),
    names_to = "Variavel",
    values_to = "Valor"
  )

ggplot(dados_z_grafico, aes(x = Variavel, y = Valor)) +
  geom_boxplot(fill = "#B0003A", alpha = 0.4) +
  coord_flip() +
  labs(
    title = "Indicadores padronizados",
    x = NULL,
    y = "Escore-z"
  ) +
  theme_minimal()
```




```
valores_atipicos = dados_z_grafico %>%
  filter(abs(Valor) > 3) %>%
  dplyr::count(Variavel, name = "Quantidade")

kable(valores_atipicos, caption = "Valores com escore-z acima de 3 em módulo")
```

Table 3: Valores com escore-z acima de 3 em módulo

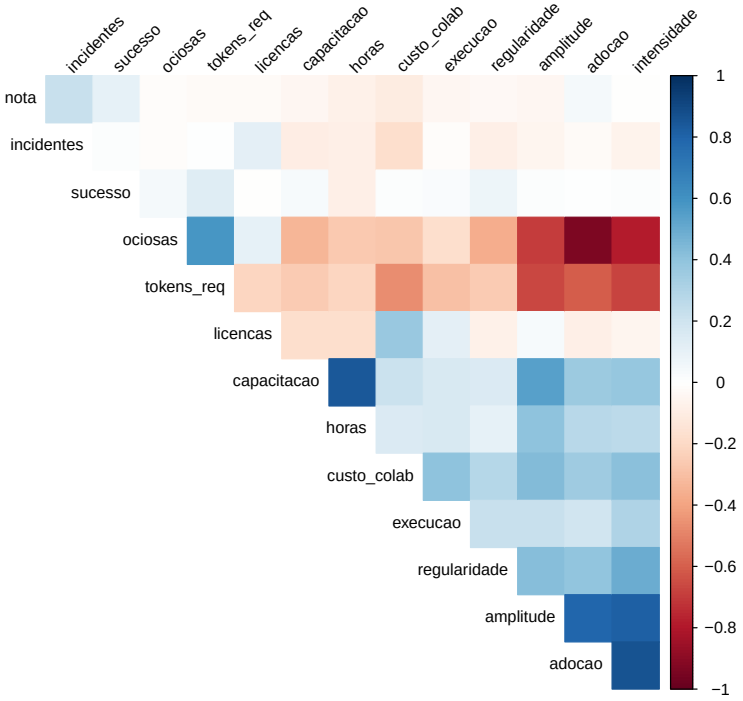
Variavel	Quantidade
execucao	1
horas	1
incidentes	3
licencas	1
nota	2
regularidade	3
sucesso	1

São poucos casos, e são valores válidos da base, não erros de cadastro. Por isso mantemos todos os departamentos. `incidentes` e `regularidade` são os indicadores com mais valores extremos.

Correlações

```
matriz_correl = cor(
  dados %>% select(all_of(variaveis_indicadores)),
  use = "pairwise.complete.obs"
)

corrplot(
  matriz_correl,
  method = "color",
  type = "upper",
  order = "hclust",
  diag = FALSE,
  tl.col = "black",
  tl.cex = 0.8,
  tl.srt = 45
)
```




```
tabela_correlacoes = as.data.frame(as.table(matriz_correl)) %>%
  rename(
    Variavel_1 = Var1,
    Variavel_2 = Var2,
    Correlacao = Freq
  ) %>%
  filter(
    as.integer(Variavel_1) < as.integer(Variavel_2)
  ) %>%
  arrange(desc(abs(Correlacao)))

kable(
  tabela_correlacoes %>% slice(1:8),
  digits = 3,
  caption = "As oito maiores correlações entre os indicadores"
)
```

Table 4: As oito maiores correlações entre os indicadores

Variavel_1	Variavel_2	Correlacao
adocao	ociosas	-0.937
adocao	intensidade	0.862
capacitacao	horas	0.846
intensidade	amplitude	0.815
adocao	amplitude	0.791
intensidade	ociosas	-0.788
amplitude	ociosas	-0.692
intensidade	tokens_req	-0.679

```r
maior_correlacao = as.data.frame(as.table(matriz_correl)) %>%
  rename(
    Variavel_1 = Var1,
    Variavel_2 = Var2,
    Correlacao = Freq
  ) %>%
  filter(Variavel_1 != Variavel_2) %>%
  group_by(Variavel_1) %>%
  summarise(Maior_correlacao = max(abs(Correlacao))) %>%
  arrange(Maior_correlacao)

kable(
  maior_correlacao,
  digits = 3,
  caption = "Maior correlação (em módulo) de cada indicador com os demais"
)
```

Table 5: Maior correlação (em módulo) de cada indicador com os demais

Variavel_1	Maior_correlacao
sucesso	0.138
nota	0.222
incidentes	0.222
licencas	0.376
execucao	0.408
custo_colab	0.468
regularidade	0.491
tokens_req	0.679
amplitude	0.815
capacitacao	0.846
horas	0.846
intensidade	0.862
adocao	0.937
ociosas	0.937

`adocao` e `ociosas` são quase espelhos (r = -0,94): onde pouca gente usa, a empresa paga licença parada.

Indicadores que saem. `sucesso`, `nota` e `incidentes` têm correlação menor que 0,30 com todos os outros indicadores, então não medem nada em comum com eles. Além disso, `nota` tem valores ausentes em 4 departamentos sem curso concluído. Por isso seguimos com 11 indicadores. Os incidentes voltam no teste da H2.

Padronização

Para cada observação (x), o escore-z é calculado por:

$$z = \frac{x - \bar{x}}{s}$$

`ociosas` e `tokens_req` funcionam ao contrário (quanto maior, pior o uso), então invertemos o sinal delas antes de padronizar.

```r
variaveis_cluster = c(
  "adocao", "intensidade", "regularidade", "amplitude", "ociosas",
  "tokens_req", "capacitacao", "horas", "custo_colab", "licencas",
  "execucao"
)

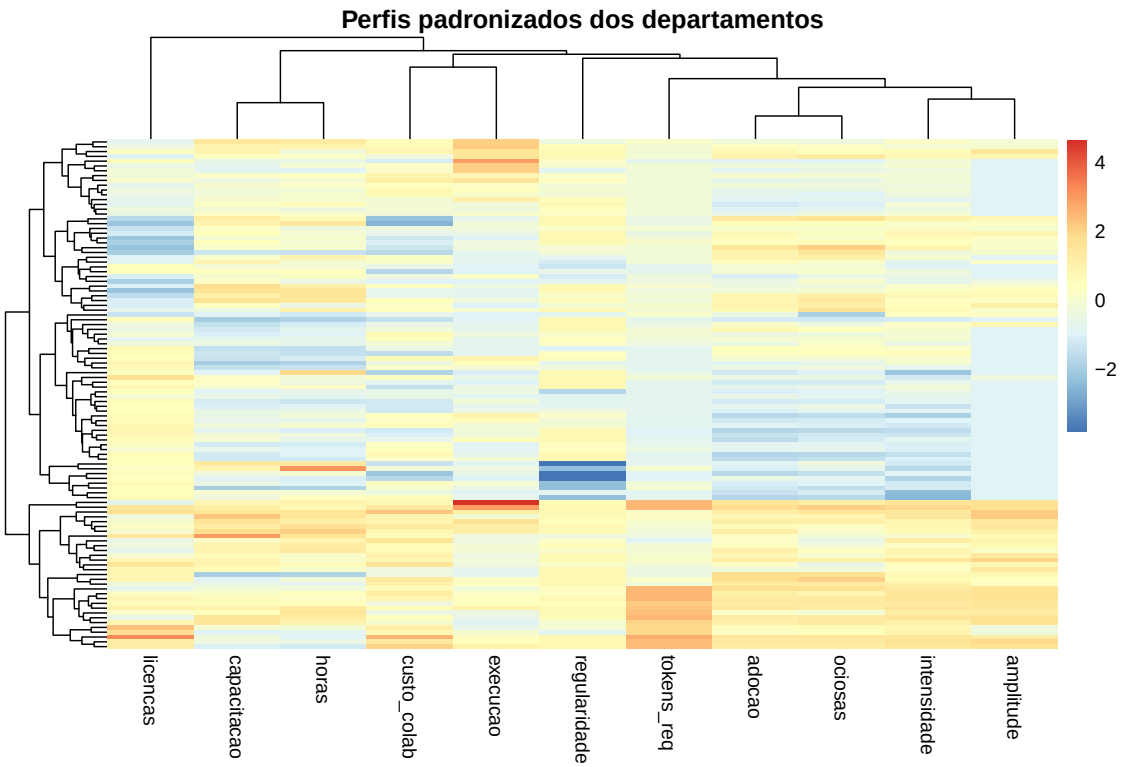
matriz_padronizada = dados %>%
  select(all_of(variaveis_cluster)) %>%
  mutate(
    ociosas = -ociosas,
    tokens_req = -tokens_req
  ) %>%
  mutate(
    across(
      everything(),
      ~ as.numeric(scale(.x))
    )
  ) %>%
  as.matrix()

rownames(matriz_padronizada) = dados$department_id
```

Dimensões dos indicadores

O mapa de calor agrupa as colunas por proximidade, então serve de evidência exploratória de quais indicadores andam juntos.

```r
pheatmap(
  matriz_padronizada,
  cluster_rows = TRUE,
  cluster_cols = TRUE,
  show_rownames = FALSE,
  border_color = NA,
  main = "Perfis padronizados dos departamentos"
)
```



Pelo gráfico e pelas correlações, enxergamos três dimensões:

- **Uso:** `adocao`, `intensidade`, `amplitude`, `ociosas`, `tokens_req` e `regularidade`. As cinco primeiras ficam bem juntas. `regularidade` é a mais distante, mas sua maior correlação é com `intensidade`, então faz sentido deixá-la aqui.
- **Capacitação:** `capacitacao` e `horas`, que formam um bloco bem separado ($r = 0{,}85$).
- **Investimento:** `custo_colab`, `execucao` e `licencas`. Esta é a dimensão mais fraca: `licencas` fica meio isolada no gráfico e tem correlações baixas, de 0,38 com `custo_colab` e 0,12 com `execucao`. Ela fica aqui pelo significado, já que licença é dinheiro gasto.

Construção automática dos indicadores-síntese

Cada dimensão vira a média dos seus itens padronizados, e depois padronizamos o resultado para as três ficarem na mesma escala.

```
itens_perfil = list(
  uso = c(
    "adocao", "intensidade", "regularidade",
    "amplitude", "ociosas", "tokens_req"
  ),
  capacitacao_dim = c("capacitacao", "horas"),
  investimento = c("custo_colab", "licencas", "execucao")
)

dados_segmentados = dados

for (nome_indicador in names(itens_perfil)) {
  itens = itens_perfil[[nome_indicador]]

  dados_segmentados[[nome_indicador]] = rowMeans(
```

```
    matriz_padronizada[, itens],
    na.rm = TRUE
  )
}

variaveis_perfil = names(itens_perfil)

dados_segmentados = dados_segmentados %>%
  mutate(
    across(
      all_of(variaveis_perfil),
      ~ as.numeric(scale(.x)),
      .names = "{.col}_z"
    )
  )
```

Índices organizacionais

- **Índice de Maturidade em IA (IMIA):** média de uso e capacitação, de 0 a 100.
- **Índice de Investimento (IINV):** dimensão de investimento, de 0 a 100.

Os dois ficam separados porque maturidade é o que o departamento faz com a IA, e investimento é quanto ele gasta para isso.

```
escala_100 = function(x) {
  100 * (x - min(x)) / (max(x) - min(x))
}

dados_segmentados = dados_segmentados %>%
  mutate(
    IMIA = escala_100((uso_z + capacitacao_dim_z) / 2),
    IINV = escala_100(investimento_z)
  )

# Departamentos sem uso entram no fim do ranking
ranking = bind_rows(
  dados_segmentados,
  sem_uso %>% mutate(IMIA = 0)
)

colunas_ranking = c(
  "department_name", "company_name", "setor", "n", "IMIA", "IINV"
)

kable(
  ranking %>%
    arrange(desc(IMIA)) %>%
    slice(1:8) %>%
    select(all_of(colunas_ranking)),
  digits = 1,
  col.names = c("Departamento", "Empresa", "Setor", "n", "IMIA", "IINV"),
  caption = "Os 8 departamentos com maior maturidade"
)
```

Table 6: Os 8 departamentos com maior maturidade

Departamento	Empresa	Setor	n	IMIA	IINV
Dados e Analytics	NexoCode Solucoes	Tecnologia	22	100.0	49.0
Produto	NexoCode Solucoes	Tecnologia	18	99.7	37.7
Produto	Vortice Software	Tecnologia	13	98.8	97.2
Dados e Analytics	Vortice Software	Tecnologia	13	97.8	92.3
Produto	Cronos Tech Labs	Tecnologia	8	95.6	68.8
Engenharia de Software	NexoCode Solucoes	Tecnologia	102	93.6	86.6
Marketing	Vortice Software	Tecnologia	6	92.6	62.3
DevOps e Infraestrutura	Cronos Tech Labs	Tecnologia	5	91.9	44.8

```
kable(
  ranking %>%
    arrange(IMIA) %>%
    slice(1:8) %>%
    select(all_of(colunas_ranking)),
  digits = 1,
  col.names = c("Departamento", "Empresa", "Setor", "n", "IMIA", "IINV"),
  caption = "Os 8 departamentos com menor maturidade"
)
```

Table 7: Os 8 departamentos com menor maturidade

Departamento	Empresa	Setor	n	IMIA	IINV
Financeiro	ServPro Facilities	Servicos	5	0.0	44.1
Risco e Compliance	Capital Sul Investimentos	Financeiro	6	0.0	NA
Compras	Quimica Bandeirantes	Industria	8	0.0	NA
RH	Compra Certa Varejo	Varejo	7	0.0	NA
Comercial	ServPro Facilities	Servicos	5	0.0	NA
Comercial e Compras	Lojas Formosa	Varejo	9	8.1	28.1
Atendimento ao Cliente	Capital Sul Investimentos	Financeiro	14	9.4	52.8
Manutencao	TextilNorte Manufatura	Industria	5	10.1	24.6

```
indice_empresas = ranking %>%
  group_by(company_name, setor) %>%
  summarise(
    Departamentos = n(),
    Colaboradores = sum(n),
    IMIA = weighted.mean(IMIA, n),
    IINV = weighted.mean(IINV, n, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  arrange(desc(IMIA))

kable(
  indice_empresas,
  digits = 1,
  col.names = c("Empresa", "Setor", "Dep.", "Colab.", "IMIA", "IINV"),
  caption = "Índices por empresa (média ponderada por colaboradores)"
)
```

Table 8: Índices por empresa (média ponderada por colaboradores)

Empresa	Setor	Dep.	Colab.	IMIA	IINV
NexoCode Solucoes	Tecnologia	10	335	86.4	65.3
Vortice Software	Tecnologia	8	104	83.5	71.8
Ideia Fresca Marketing	Marketing	3	31	76.0	7.1
Cronos Tech Labs	Tecnologia	10	95	72.8	48.8
Prisma Consultoria Empresarial	Servicos	7	74	72.4	30.1
Piloto Digital Sistemas	Tecnologia	2	15	67.1	89.1
Estrela Marketing Digital	Marketing	4	58	66.4	52.9
MercadoPrime E-commerce	Varejo	8	114	59.1	25.3
ByteFlow Engenharia de Software	Tecnologia	2	11	54.4	68.5
Fincredi Solucoes Financeiras	Financeiro	2	24	46.1	44.1
Banco Alterosa S.A.	Financeiro	8	316	42.2	51.5
Compra Certa Varejo	Varejo	9	249	39.0	44.1
Lojas Formosa	Varejo	6	70	28.2	31.3
Quimica Bandeirantes	Industria	9	127	27.5	49.7
TextilNorte Manufatura	Industria	3	22	26.6	26.1
ServPro Facilities	Servicos	4	30	24.7	47.9
Metalurgica Vale Forte	Industria	9	306	24.7	55.1
Capital Sul Investimentos	Financeiro	6	63	19.6	41.7

```
indice_setores = ranking %>%
  group_by(setor) %>%
  summarise(
    Departamentos = n(),
    IMIA = weighted.mean(IMIA, n),
    IINV = weighted.mean(IINV, n, na.rm = TRUE),
    .groups = "drop"
  ) %>%
  arrange(desc(IMIA))

kable(
  indice_setores,
  digits = 1,
  caption = "Índices por setor (média ponderada por colaboradores)"
)
```

Table 9: Índices por setor (média ponderada por colaboradores)

setor	Departamentos	IMIA	IINV
Tecnologia	32	82.4	64.4
Marketing	7	69.7	37.0
Servicos	11	58.7	34.6
Varejo	23	42.5	37.0
Financeiro	16	38.9	49.6
Industria	21	25.6	52.2

Maturidade × investimento

Cortando os dois índices na mediana, cada departamento cai em um quadrante.

```r
mediana_imia = median(dados_segmentados$IMIA)
mediana_iinv = median(dados_segmentados$IINV)

dados_segmentados = dados_segmentados %>%
  mutate(
    Quadrante = if_else(
      IMIA >= mediana_imia,
      if_else(IINV >= mediana_iinv, "Avançado", "Eficiente"),
      if_else(IINV >= mediana_iinv, "Desperdício", "Inicial")
    )
  )

tabela_quadrantes = dados_segmentados %>%
  dplyr::count(Quadrante, name = "Departamentos")

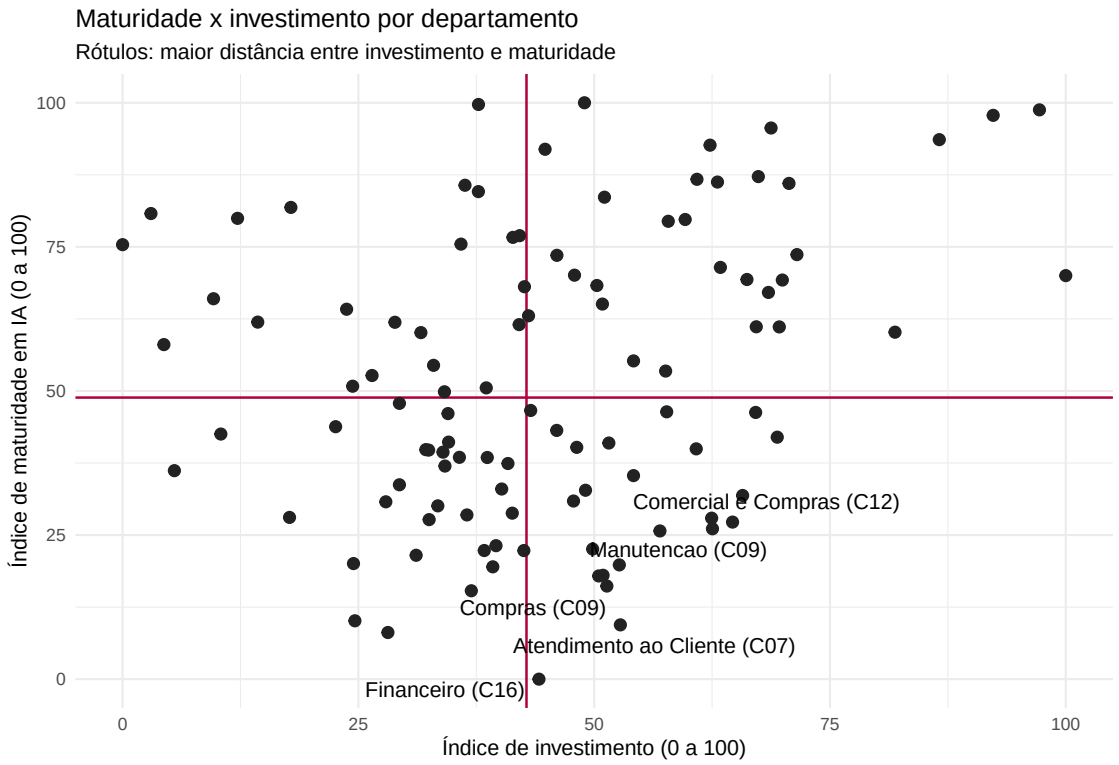
kable(tabela_quadrantes, caption = "Departamentos por quadrante")
```

Table 10: Departamentos por quadrante

Quadrante	Departamentos
Avançado	30
Desperdício	23
Eficiente	23
Inicial	30

```r
maiores_desperdicios = dados_segmentados %>%
  filter(Quadrante == "Desperdício") %>%
  arrange(desc(IINV - IMIA)) %>%
  slice(1:5) %>%
  mutate(Rotulo = paste0(department_name, " (", company_id, ")"))

ggplot(dados_segmentados, aes(x = IINV, y = IMIA)) +
  geom_hline(yintercept = mediana_imia, color = "#B0003A", linewidth = 0.6) +
  geom_vline(xintercept = mediana_iinv, color = "#B0003A", linewidth = 0.6) +
  geom_point(size = 2.5, color = "#222222") +
  geom_text_repel(
    data = maiores_desperdicios,
    aes(label = Rotulo),
    seed = 123,
    box.padding = 0.4,
    point.padding = 0.3,
    max.overlaps = Inf
  ) +
  labs(
    title = "Maturidade x investimento por departamento",
    subtitle = "Rótulos: maior distância entre investimento e maturidade",
    x = "Índice de investimento (0 a 100)",
    y = "Índice de maturidade em IA (0 a 100)"
  ) +
  theme_minimal()
```



São 23 departamentos no quadrante de **desperdício**, que gastam acima da mediana e têm maturidade abaixo dela.

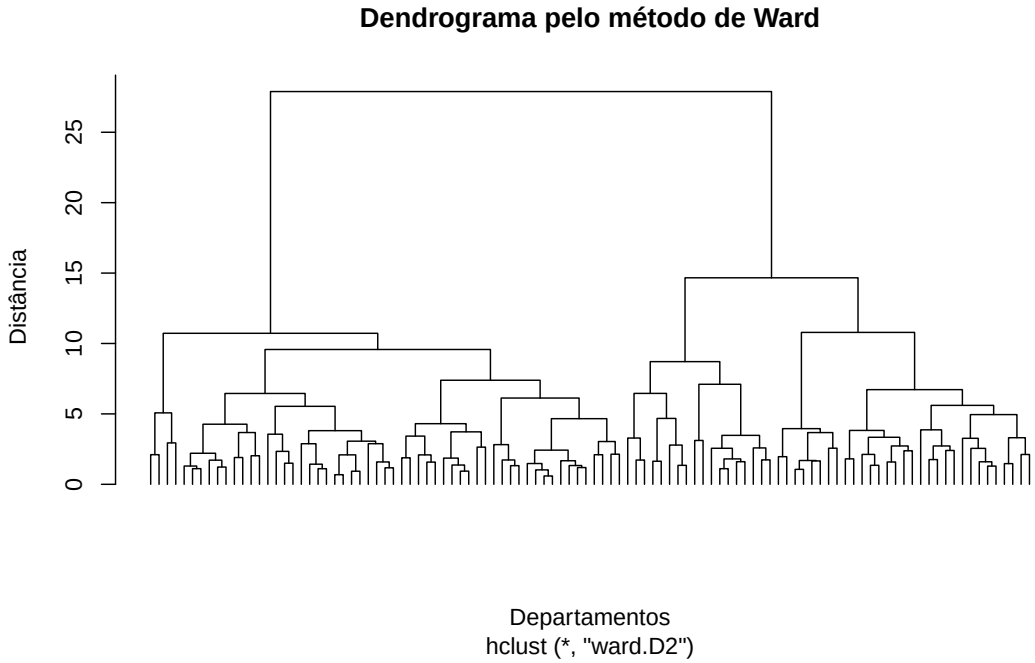
Agrupamento hierárquico

Agora a segmentação. Usamos os 11 indicadores padronizados, a distância euclidiana e o método de Ward.

```
distancias = dist(
  matriz_padronizada,
  method = "euclidean"
)

ajuste_hierarquico = hclust(
  distancias,
  method = "ward.D2"
)

plot(
  ajuste_hierarquico,
  labels = FALSE,
  main = "Dendrograma pelo método de Ward",
  xlab = "Departamentos",
  ylab = "Distância",
  hang = -1
)
```



Escolha do número de grupos

Comparamos as soluções pelo WSS (cotovelo), pela silhueta e pela concordância entre o k-means e o agrupamento hierárquico (índice de Rand ajustado).

```
k_min = 2
k_max_desejado = 10

k_max = min(
  k_max_desejado,
  nrow(matriz_padronizada) - 1
)

avaliacao_k = map_dfr(
  1:k_max,
  function(k) {
    set.seed(semente)

    ajuste = kmeans(
      matriz_padronizada,
      centers = k,
      nstart = 50,
      iter.max = 100
    )

    silhueta_media = if (k == 1) {
      NA_real_
    } else {
      mean(
        silhouette(
          ajuste$cluster,
```

```
          distancias
        )[, "sil_width"]
      )
    }

    concordancia = if (k == 1) {
      NA_real_
    } else {
      adjustedRandIndex(
        cutree(ajuste_hierarquico, k = k),
        ajuste$cluster
      )
    }

    tibble(
      k = k,
      WSS = ajuste$tot.withinss,
      Silhueta_media = silhueta_media,
      ARI_hierarquico = concordancia
    )
  }
)

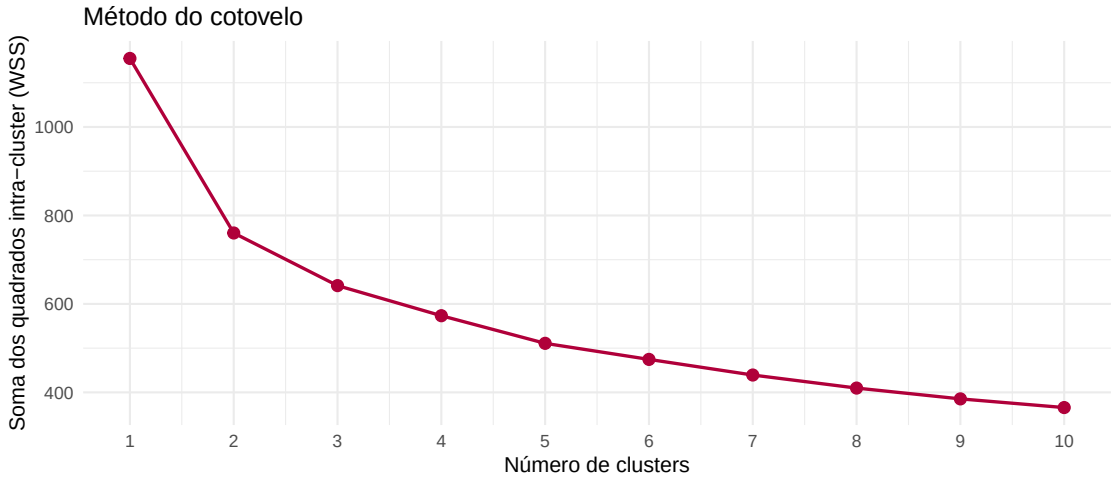
kable(
  avaliacao_k,
  digits = 3,
  caption = "Avaliação das soluções para diferentes números de grupos"
)
```

Table 11: Avaliação das soluções para diferentes números de grupos

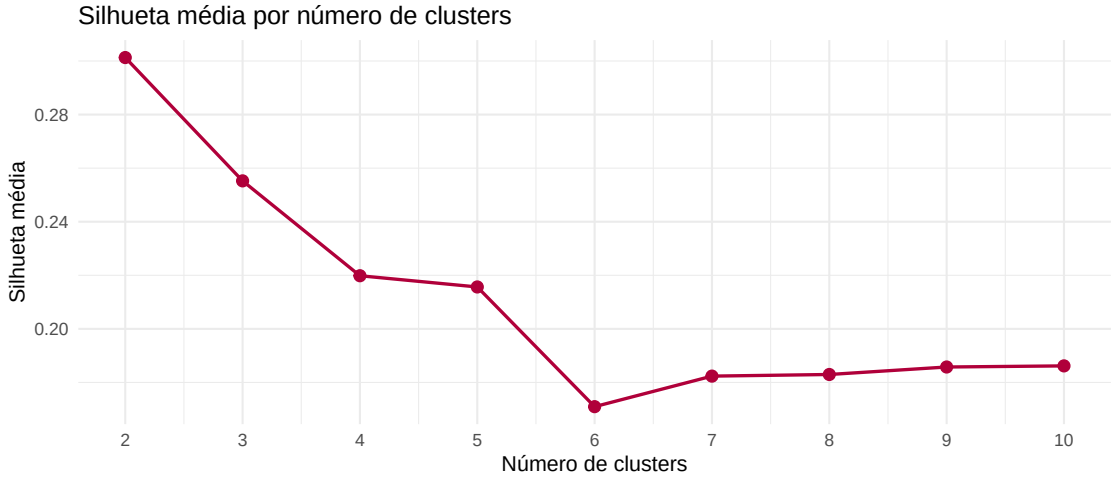
k	WSS	Silhueta_media	ARI_hierarquico
1	1155.000	NA	NA
2	760.355	0.301	0.889
3	641.344	0.255	0.836
4	573.313	0.220	0.624
5	510.878	0.216	0.684
6	474.553	0.171	0.591
7	439.213	0.182	0.596
8	409.720	0.183	0.678
9	385.281	0.186	0.607
10	365.687	0.186	0.660

```
ggplot(avaliacao_k, aes(x = k, y = WSS)) +
  geom_line(color = "#B0003A", linewidth = 0.8) +
  geom_point(color = "#B0003A", size = 2.5) +
  scale_x_continuous(breaks = 1:k_max) +
  labs(
    title = "Método do cotovelo",
    x = "Número de clusters",
    y = "Soma dos quadrados intra-cluster (WSS)"
  ) +
```

```
  theme_minimal()
```




```
ggplot(
  filter(avaliacao_k, !is.na(Silhueta_media)),
  aes(x = k, y = Silhueta_media)
) +
  geom_line(color = "#B0003A", linewidth = 0.8) +
  geom_point(color = "#B0003A", size = 2.5) +
  scale_x_continuous(breaks = k_min:k_max) +
  labs(
    title = "Silhueta média por número de clusters",
    x = "Número de clusters",
    y = "Silhueta média"
  ) +
  theme_minimal()
```

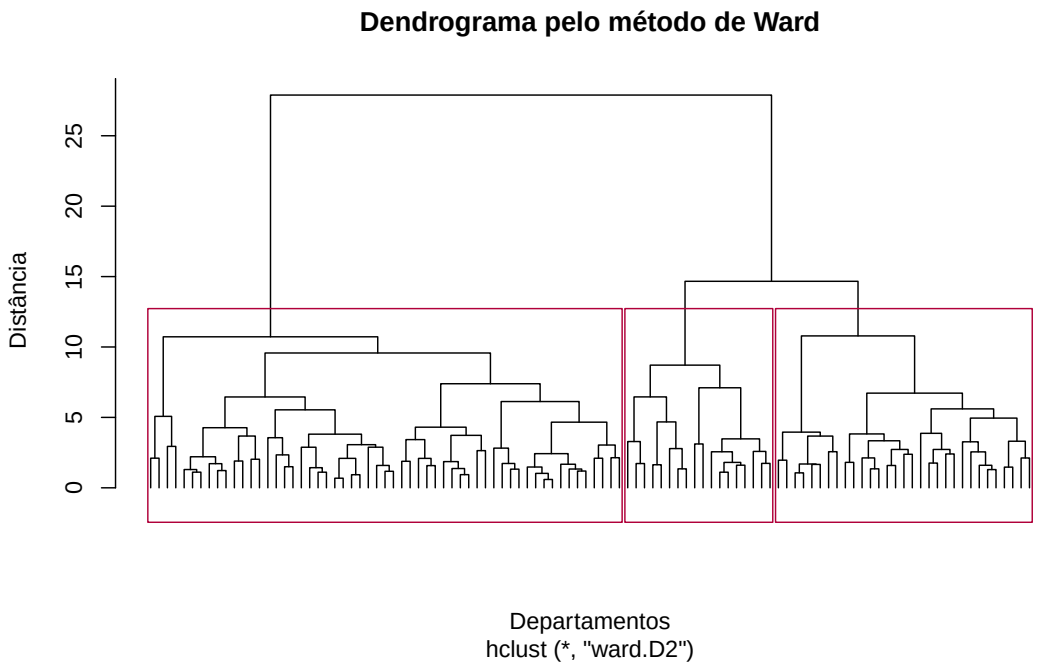


A maior silhueta é a de 2 grupos, mas essa solução só separa quem usa muito de quem usa pouco e ajuda pouco na decisão. Escolhemos **3 grupos** porque a silhueta ainda é a segunda maior (0,255), o k-means e o hierárquico concordam bastante (ARI de 0,836, contra 0,624 com 4 grupos) e a curva do WSS já começa a achatar. Mesmo assim a silhueta é baixa, ou seja, os grupos existem, mas não são muito separados.

```r
numero_clusters = 3

plot(
  ajuste_hierarquico,
  labels = FALSE,
  main = "Dendrograma pelo método de Ward",
  xlab = "Departamentos",
  ylab = "Distância",
  hang = -1
)

rect.hclust(
  ajuste_hierarquico,
  k = numero_clusters,
  border = "#B0003A"
)
```




```r
grupos_hierarquicos = cutree(
  ajuste_hierarquico,
  k = numero_clusters
)
```

K-means

```r
set.seed(semente)

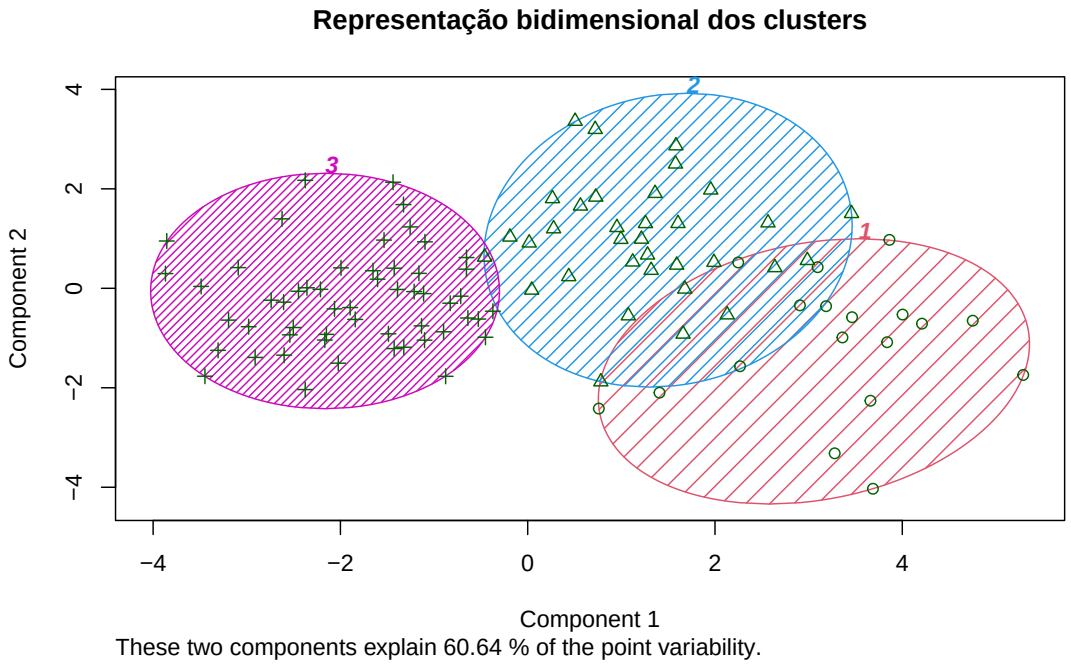
ajuste_kmeans = kmeans(
  matriz_padronizada,
  centers = numero_clusters,
  nstart = 50,
```

```
  iter.max = 100
)

dados_segmentados = dados_segmentados %>%
  mutate(
    Cluster = factor(ajuste_kmeans$cluster)
  )
```

Representação em duas dimensões

```
clusplot(
  matriz_padronizada,
  ajuste_kmeans$cluster,
  color = TRUE,
  shade = TRUE,
  labels = 4,
  lines = 0,
  main = "Representação bidimensional dos clusters"
)
```

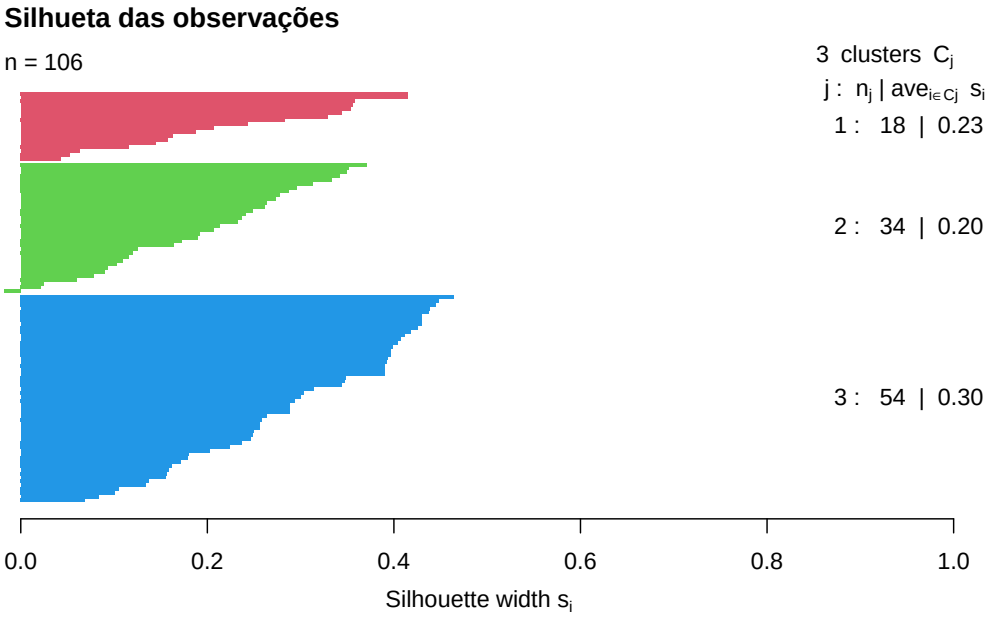


Silhueta de cada observação

```
silhueta_observacoes = silhouette(
  ajuste_kmeans$cluster,
  distancias
)

plot(
  silhueta_observacoes,
  col = 2:(numero_clusters + 1),
```

```
  border = NA,
  main = "Silhueta das observações"
)
```



K-means++ e comparação das soluções

```
set.seed(semente)

ajuste_kmeans_mais = KMeans_rcpp(
  matriz_padronizada,
  clusters = numero_clusters,
  num_init = 20,
  max_iters = 100,
  initializer = "kmeans++"
)

clusters_kmeans_mais = ajuste_kmeans_mais$clusters

indice_rand = tibble(
  Comparacao = c(
    "Hierárquico × k-means",
    "Hierárquico × k-means++",
    "k-means × k-means++"
  ),
  ARI = c(
    adjustedRandIndex(grupos_hierarquicos, ajuste_kmeans$cluster),
    adjustedRandIndex(grupos_hierarquicos, clusters_kmeans_mais),
    adjustedRandIndex(ajuste_kmeans$cluster, clusters_kmeans_mais)
  )
)
```

```r
kable(
  indice_rand,
  digits = 3,
  caption = "Concordância entre as soluções pelo índice de Rand ajustado"
)
```

Table 12: Concordância entre as soluções pelo índice de Rand ajustado

Comparacao	ARI
Hierárquico × k-means	0.836
Hierárquico × k-means++	0.836
k-means × k-means++	1.000

O k-means e o k-means++ chegam ao mesmo resultado e o hierárquico fica bem próximo, então os grupos dependem pouco do método escolhido.

Perfil dos grupos

```r
perfil_padronizado = dados_segmentados %>%
  group_by(Cluster) %>%
  summarise(
    across(
      ends_with("_z"),
      ~ mean(.x, na.rm = TRUE)
    ),
    n = n(),
    .groups = "drop"
  ) %>%
  # Os nomes seguem a ordem do uso, do menor para o maior
  arrange(uso_z) %>%
  mutate(
    Perfil = c(
      "Adoção baixa",
      "Capacitados, investimento baixo",
      "Avançados"
    )
  )

kable(
  perfil_padronizado %>% select(Perfil, ends_with("_z"), n),
  digits = 2,
  col.names = c("Perfil", "Uso", "Capacitação", "Investimento", "n"),
  caption = "Perfil padronizado dos clusters"
)
```

Table 13: Perfil padronizado dos clusters

Perfil	Uso	Capacitação	Investimento	n
Adoção baixa	-0.81	-0.53	-0.18	54

Perfil	Uso	Capacitação	Investimento	n
Capacitados, investimento baixo	0.48	0.66	-0.29	34
Avançados	1.52	0.34	1.09	18

```
dados_segmentados = dados_segmentados %>%
  mutate(
    Perfil = factor(
      Cluster,
      levels = perfil_padronizado$Cluster,
      labels = perfil_padronizado$Perfil
    )
  )

perfil_original = dados_segmentados %>%
  group_by(Perfil) %>%
  summarise(
    Colaboradores = sum(n),
    across(
      c(adocao, capacitacao, ociosas, execucao, incidentes),
      ~ mean(.x, na.rm = TRUE)
    ),
    .groups = "drop"
  )

kable(
  perfil_original,
  digits = 2,
  caption = "Perfil dos clusters nas escalas originais"
)
```

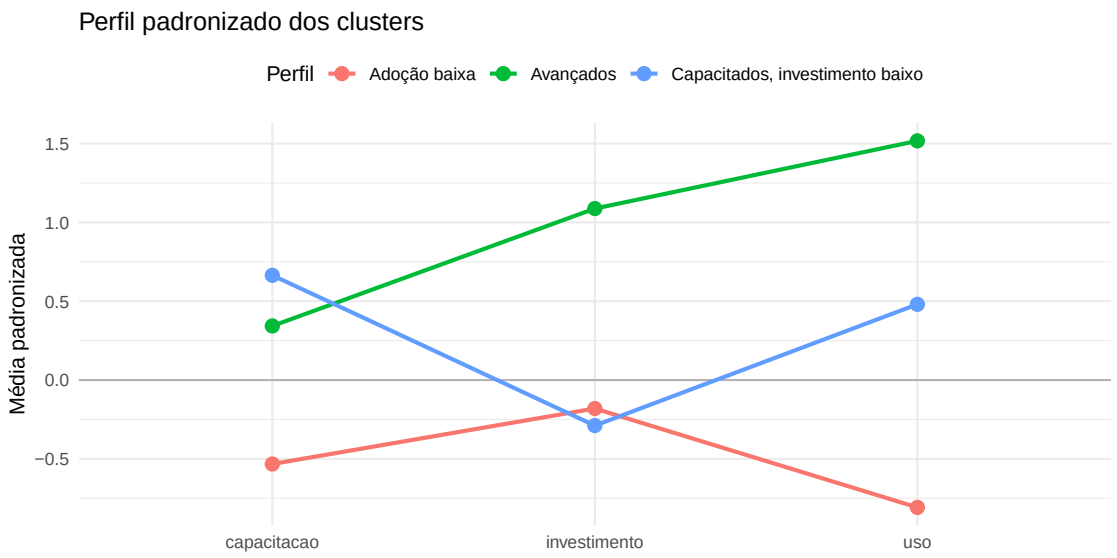
Table 14: Perfil dos clusters nas escalas originais

Perfil	Colaboradores	adocao	capacitacao	ociosas	execucao	incidentes
Adoção baixa	1163	0.31	0.25	0.71	0.71	4.68
Capacitados, investimento baixo	506	0.69	0.47	0.39	0.82	3.02
Avançados	349	0.83	0.41	0.22	1.19	4.46

```
perfil_grafico = perfil_padronizado %>%
  select(-n, -Cluster) %>%
  pivot_longer(
    cols = ends_with("_z"),
    names_to = "Indicador",
    values_to = "Media_padronizada"
  ) %>%
  mutate(
    Indicador = str_remove(Indicador, "_z$"),
    Indicador = str_remove(Indicador, "_dim$")
  )

ggplot(
```

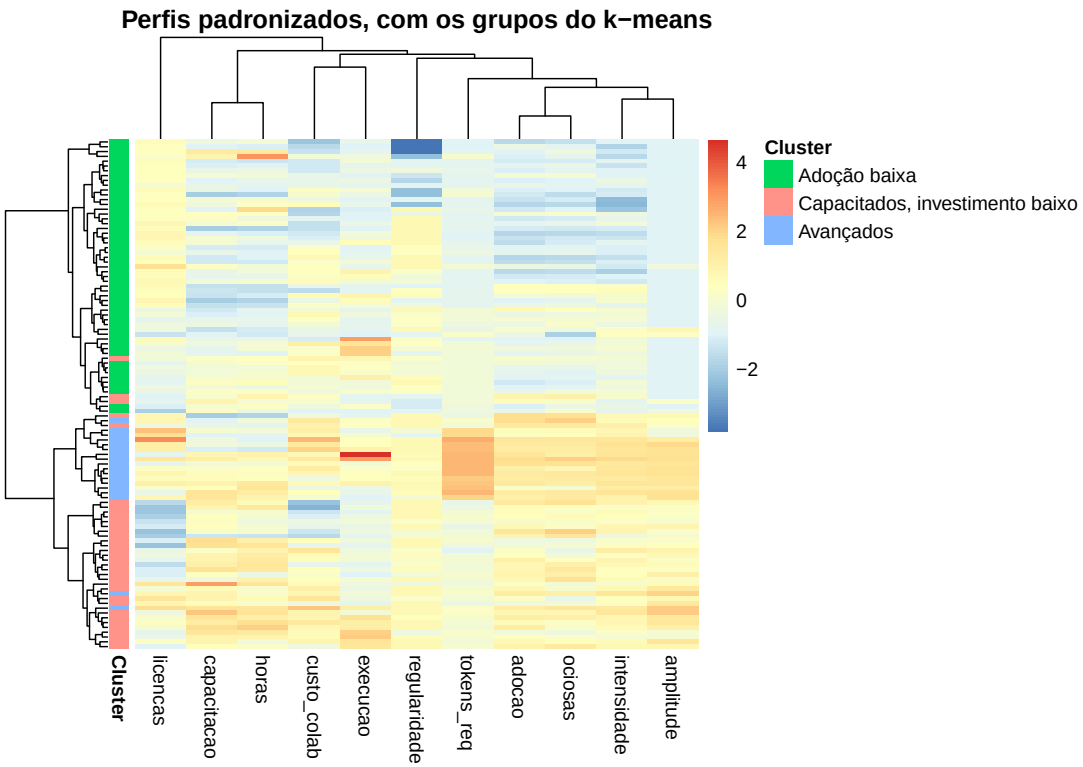
```
  perfil_grafico,
  aes(
    x = Indicador,
    y = Media_padronizada,
    color = Perfil,
    group = Perfil
  )
) +
  geom_hline(yintercept = 0, color = "grey70") +
  geom_line(linewidth = 1) +
  geom_point(size = 3) +
  labs(
    title = "Perfil padronizado dos clusters",
    x = NULL,
    y = "Média padronizada"
  ) +
  theme_minimal() +
  theme(legend.position = "top")
```




```
anotacao_linhas = data.frame(
  Cluster = factor(dados_segmentados$Perfil)
)

rownames(anotacao_linhas) = rownames(matriz_padronizada)

pheatmap(
  matriz_padronizada,
  cluster_rows = ajuste_hierarquico,
  cluster_cols = TRUE,
  annotation_row = anotacao_linhas,
  show_rownames = FALSE,
  border_color = NA,
  main = "Perfis padronizados, com os grupos do k-means"
)
```

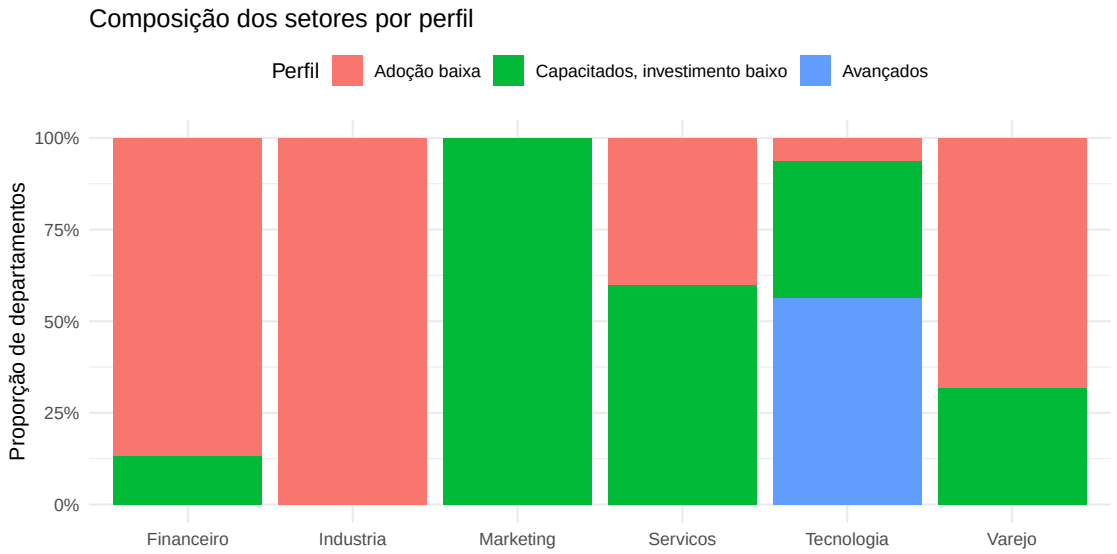


Composição dos grupos por setor

O setor não participou da formação dos grupos. Se um setor predomina em um grupo, isso é resultado da análise.

```
composicao_setores = dados_segmentados %>%
  dplyr::count(setor, Perfil, name = "Quantidade") %>%
  group_by(setor) %>%
  mutate(Proporcao = Quantidade / sum(Quantidade)) %>%
  ungroup()

ggplot(composicao_setores, aes(x = setor, y = Proporcao, fill = Perfil)) +
  geom_col() +
  scale_y_continuous(labels = scales::label_percent()) +
  labs(
    title = "Composição dos setores por perfil",
    x = NULL,
    y = "Proporção de departamentos"
  ) +
  theme_minimal() +
  theme(legend.position = "top")
```



Uso sem capacitação

Com 3 grupos não aparece um grupo só de "usa muito e treina pouco", mas podemos encontrar esses departamentos direto, filtrando quem está acima da média em uso e abaixo da média em capacitação.

```
uso_sem_capacitacao = dados_segmentados %>%
  filter(uso_z > 0, capacitacao_dim_z < 0) %>%
  arrange(capacitacao_dim_z)

kable(
  uso_sem_capacitacao %>%
    select(department_name, company_name, adocao, capacitacao) %>%
    slice(1:8),
  digits = 2,
  col.names = c("Departamento", "Empresa", "Adoção", "Capacitação"),
  caption = "Departamentos com uso alto e menor capacitação (8 primeiros)"
)
```

Table 15: Departamentos com uso alto e menor capacitação (8 primeiros)

Departamento	Empresa	Adoção	Capacitação
RH	Cronos Tech Labs	1.00	0.00
E-commerce	Lojas Formosa	0.62	0.12
Financeiro	MercadoPrime E-commerce	0.75	0.12
Vendas	Cronos Tech Labs	0.55	0.09
Qualidade (QA)	Vortice Software	0.83	0.17
Tecnologia da Informacao	Compra Certa Varejo	0.71	0.14
DevOps e Infraestrutura	ByteFlow Engenharia de Software	0.60	0.20
Midia e Performance	Estrela Marketing Digital	0.88	0.25

São 16 departamentos nessa situação, que é a de maior risco de governança: as pessoas usam IA com pouca formação. Esse risco é de gestão, e não uma previsão de incidentes, já que `incidentes` não se correlaciona com os outros indicadores.

H1: treinamento aumenta o uso de IA?

Agora mudamos o nível de análise: cada linha é um **colaborador ativo**. A resposta da regressão logística precisa ser binária, então usamos `usa_ia`: **Sim** se o colaborador fez ao menos uma requisição bem-sucedida no período.

```
dados_colab = bind_rows(empresas, colaboradores) %>%
  group_by(company_id) %>%
  mutate(industry = industry[1]) %>%
  ungroup() %>%
  filter(!is.na(employee_id)) %>%
  mutate(
    usa_ia = if_else(req > 0, "Sim", "Nao"),
    teve_incidente = if_else(inc > 0, "Sim", "Nao"),
    licencas = lic,
    tempo_casa = as.numeric(as.Date("2026-07-31") - hire_date) / 365,
    log_req = log(1 + req / length(meses)),
    senioridade = seniority,
    setor = str_remove(industry, " / Desenvolvimento de Software")
  )
```

```
variavel_id = "employee_id"
variavel_resposta = "usa_ia"

variaveis_quanti = c("cursos", "licencas", "tempo_casa")

variaveis_quali = c("senioridade", "setor")
```

Amostra de treino x amostra de teste

```
tabela_distribuicao = dados_colab %>%
  count(.data[[variavel_resposta]], name = "Frequencia") %>%
  mutate(Proporcao = Frequencia / sum(Frequencia)) %>%
  rename(Categoria = all_of(variavel_resposta))

kable(
  tabela_distribuicao,
  digits = 3,
  caption = "Distribuição da variável resposta na amostra geral"
)
```

Table 16: Distribuição da variável resposta na amostra geral

Categoria	Frequencia	Proporcao
Nao	1119	0.519
Sim	1039	0.481

```
set.seed(2026)

dados_treino = dados_colab %>%
  group_by(.data[[variavel_resposta]]) %>%
  slice_sample(prop = 0.70) %>%
  ungroup()
```

```r
dados_teste = dados_colab %>%
  anti_join(
    dados_treino %>% select(all_of(variavel_id)),
    by = variavel_id
  )

# Função reutilizável para conferir as proporções
distribuicao_por_amostra = function(base, nome_amostra) {
  base %>%
    count(.data[[variavel_resposta]], name = "Frequencia") %>%
    mutate(
      Amostra = nome_amostra,
      Proporcao = Frequencia / sum(Frequencia)
    ) %>%
    rename(Categoria = all_of(variavel_resposta))
}

bind_rows(
  distribuicao_por_amostra(dados_treino, "Treino"),
  distribuicao_por_amostra(dados_teste, "Teste")
) %>%
  kable(digits = 3, caption = "Distribuição por amostra")
```

Table 17: Distribuição por amostra

Categoria	Frequencia	Amostra	Proporcao
Nao	783	Treino	0.519
Sim	727	Treino	0.481
Nao	336	Teste	0.519
Sim	312	Teste	0.481

Criação de dummies

```r
categorias_referencia = c(
  senioridade = "Junior",
  setor = "Industria"
)

dados_treino = dados_treino %>%
  mutate(
    across(
      all_of(variaveis_quali),
      ~ relevel(
        factor(.x),
        ref = categorias_referencia[[cur_column()]]
      )
    ),
    "{variavel_resposta}" := factor(
      .data[[variavel_resposta]],
      levels = c("Nao", "Sim")
    )
```

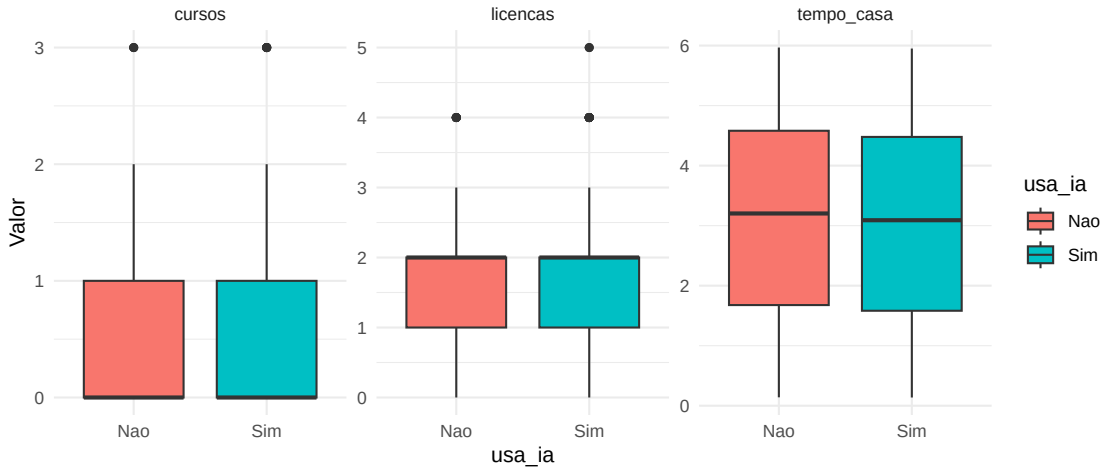
```
  )

dados_teste = dados_teste %>%
  mutate(
    across(
      all_of(variaveis_quali),
      ~ factor(
        .x,
        levels = levels(
          dados_treino[[cur_column()]]
        )
      )
    ),
    "{variavel_resposta}" := factor(
      .data[[variavel_resposta]],
      levels = levels(
        dados_treino[[variavel_resposta]]
      )
    )
  )
```

Análise descritiva

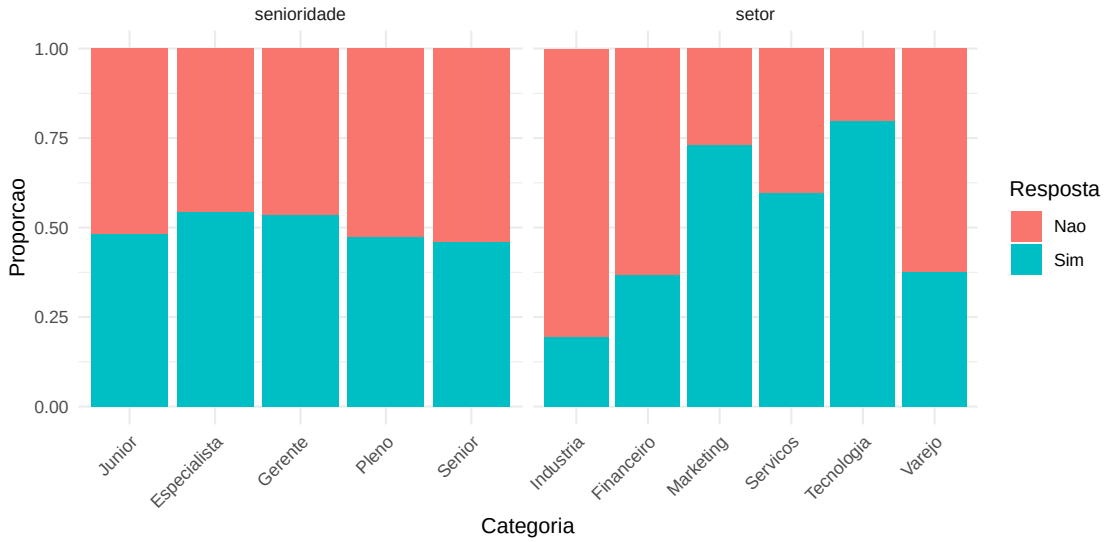
```
dados_quanti_grafico = dados_treino %>%
  select(all_of(c(variavel_resposta, variaveis_quanti))) %>%
  pivot_longer(
    cols = all_of(variaveis_quanti),
    names_to = "Variavel",
    values_to = "Valor"
  )

ggplot(dados_quanti_grafico,
       aes(x = .data[[variavel_resposta]], y = Valor,
           fill = .data[[variavel_resposta]])) +
  geom_boxplot() +
  facet_wrap(~ Variavel, scales = "free_y") +
  theme_minimal()
```



```r
dados_quali_grafico = dados_treino %>%
  select(all_of(c(variavel_resposta, variaveis_quali))) %>%
  pivot_longer(
    cols = all_of(variaveis_quali),
    names_to = "Variavel", values_to = "Categoria"
  ) %>%
  count(Variavel, Categoria,
        Resposta = .data[[variavel_resposta]]) %>%
  group_by(Variavel, Categoria) %>%
  mutate(Proporcao = n / sum(n)) %>% ungroup()

ggplot(dados_quali_grafico,
       aes(Categoria, Proporcao, fill = Resposta)) +
  geom_col() + facet_wrap(~ Variavel, scales = "free_x") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1))
```



O setor separa bem quem usa de quem não usa. A senioridade quase não muda a proporção.

Modelo sem controles e modelo com controles

```r
modelo_simples = glm(
  usa_ia ~ cursos,
  data = dados_treino,
  family = binomial(link = "logit")
)

formula_modelo = reformulate(
  termlabels = c(variaveis_quanti, variaveis_quali),
  response = variavel_resposta
)

# Modelo preliminar, com todos os controles
modelo1 = glm(
  formula = formula_modelo,
```

```
  data = dados_treino,
  family = binomial(link = "logit")
)

tabela_coeficientes = function(modelo) {
  as.data.frame(coef(summary(modelo))) %>%
    rownames_to_column("Termo") %>%
    rename(
      Estimativa = Estimate,
      Erro_padrao = `Std. Error`,
      Estatistica_z = `z value`,
      Valor_p = `Pr(>|z|)`
    ) %>%
    mutate(
      across(c(Estimativa, Erro_padrao, Estatistica_z), ~ round(.x, 3)),
      Valor_p = format.pval(Valor_p, digits = 3, eps = 0.001)
    )
}

kable(
  tabela_coeficientes(modelo1),
  caption = "Modelo logístico preliminar (H1)"
)
```

Table 18: Modelo logístico preliminar (H1)

Termo	Estimativa	Erro_padrao	Estatistica_z	Valor_p
(Intercept)	-1.136	0.245	-4.627	<0.001
cursos	0.042	0.091	0.465	0.642
licencas	-0.127	0.077	-1.650	0.099
tempo_casa	-0.029	0.035	-0.831	0.406
senioridadeEspecialista	0.276	0.232	1.190	0.234
senioridadeGerente	0.121	0.295	0.411	0.681
senioridadePleno	0.033	0.149	0.222	0.824
senioridadeSenior	-0.063	0.164	-0.384	0.701
setorFinanceiro	0.828	0.187	4.417	<0.001
setorMarketing	2.360	0.291	8.108	<0.001
setorServicos	1.718	0.285	6.036	<0.001
setorTecnologia	2.785	0.187	14.872	<0.001
setorVarejo	0.849	0.188	4.524	<0.001

Multicolinearidade

```
resultado_gvif = car::vif(modelo1)

tabela_gvif = resultado_gvif %>%
  as.data.frame() %>%
  rownames_to_column("Termo") %>%
  rename(
    Graus_liberdade = Df,
    GVIF_ajustado = `GVIF^(1/(2*Df))`
  )
```

```r
kable(
  tabela_gvif,
  digits = 3,
  col.names = c("Termo", "GVIF", "Graus de liberdade", "GVIF ajustado"),
  caption = "Fatores generalizados de inflação da variância"
)
```

Table 19: Fatores generalizados de inflação da variância

Termo	GVIF	Graus de liberdade	GVIF ajustado
cursos	1.035	1	1.017
licencas	1.109	1	1.053
tempo_casa	1.014	1	1.007
senioridade	1.030	4	1.004
setor	1.158	5	1.015

Todos os GVIF ajustados estão abaixo de 2,24 (equivalente a VIF = 5), então não há multicolinearidade e nenhuma variável precisa sair por esse motivo.

O efeito do curso muda com os controles?

```r
# Razão de chances de cada curso concluído em um modelo
or_cursos = function(modelo, nome_modelo) {
  ic_wald = confint.default(modelo)

  tibble(
    Modelo = nome_modelo,
    OR = exp(coef(modelo)["cursos"]),
    IC_95_inferior = exp(ic_wald["cursos", 1]),
    IC_95_superior = exp(ic_wald["cursos", 2]),
    Valor_p = coef(summary(modelo))["cursos", 4]
  )
}

tabela_h1 = bind_rows(
  or_cursos(modelo_simples, "Sem controles"),
  or_cursos(modelo1, "Com controles")
)

kable(
  tabela_h1 %>%
    mutate(Valor_p = format.pval(Valor_p, digits = 3, eps = 0.001)),
  digits = 3,
  caption = "H1: razão de chances de usar IA por curso concluído"
)
```

Table 20: H1: razão de chances de usar IA por curso concluído

Modelo	OR	IC_95_inferior	IC_95_superior	Valor_p
Sem controles	1.366	1.166	1.600	<0.001
Com controles	1.043	0.872	1.248	0.642

Contribuição de cada variável

```
contribuicao_h1 = drop1(modelo1, test = "Chisq")

contribuicao_h1
```

```
## Single term deletions
##
## Model:
## usa_ia ~ cursos + licencas + tempo_casa + senioridade + setor
##             Df Deviance    AIC    LRT            Pr(>Chi)
## <none>           1731.1 1757.1
## cursos       1   1731.4 1755.4   0.22              0.6423
## licencas     1   1733.9 1757.9   2.72              0.0993 .
## tempo_casa   1   1731.8 1755.8   0.69              0.4059
## senioridade  4   1733.4 1751.4   2.25              0.6892
## setor        5   2070.8 2086.8 339.63 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Seleção pelo AIC

```
modelo_aic = step(modelo1, direction = "backward", trace = 0)

formula(modelo_aic)
```

```
## usa_ia ~ licencas + setor
```

```
kable(
  tabela_coeficientes(modelo_aic),
  caption = "Modelo selecionado pelo AIC (H1)"
)
```

Table 21: Modelo selecionado pelo AIC (H1)

Termo	Estimativa	Erro_padrao	Estatistica_z	Valor_p
(Intercept)	-1.197	0.200	-5.974	<0.001
licencas	-0.125	0.077	-1.623	0.104
setorFinanceiro	0.840	0.186	4.506	<0.001
setorMarketing	2.355	0.290	8.132	<0.001
setorServicos	1.748	0.282	6.203	<0.001
setorTecnologia	2.801	0.185	15.157	<0.001
setorVarejo	0.860	0.187	4.601	<0.001

Razões de chances

```
ic_wald = confint.default(modelo_aic)

tabela_or = tibble(
  Termo = names(coef(modelo_aic)),
  OR = exp(coef(modelo_aic)),
  IC_95_inferior = exp(ic_wald[, 1]),
  IC_95_superior = exp(ic_wald[, 2])
```

```
) %>%
  filter(Termo != "(Intercept)") %>%
  mutate(across(where(is.numeric), ~ round(.x, 3)))

kable(
  tabela_or,
  caption = "Razões de chances e intervalos de 95%"
)
```

Table 22: Razões de chances e intervalos de 95%

Termo	OR	IC_95_inferior	IC_95_superior
licencas	0.883	0.759	1.026
setorFinanceiro	2.316	1.607	3.337
setorMarketing	10.540	5.975	18.594
setorServicos	5.745	3.307	9.982
setorTecnologia	16.457	11.456	23.639
setorVarejo	2.363	1.638	3.408

Desempenho na amostra de teste

```
# Cálculo das probabilidades de ocorrência na amostra
dados_teste = dados_teste %>%
  mutate(
    p_ocorrencia = predict(modelo_aic, newdata = dados_teste, type = "response")
  )

# Classificação dos colaboradores
ponto_corte = 0.50

dados_teste = dados_teste %>%
  mutate(
    classe_prevista = if_else(p_ocorrencia >= ponto_corte, "Sim", "Nao"),
    classe_prevista = factor(classe_prevista, levels = c("Nao", "Sim"))
  )

# Matriz de confusão
matriz = table(
  Previsto = dados_teste$classe_prevista,
  Real = dados_teste[[variavel_resposta]]
)

tab_matriz = cbind(matriz)
rownames(tab_matriz) = c("Previsto: Nao", "Previsto: Sim")
colnames(tab_matriz) = c("Real: Nao", "Real: Sim")

kable(tab_matriz, caption = "Matriz de confusão: ponto de corte = 0,50")
```

Table 23: Matriz de confusão: ponto de corte = 0,50

	Real: Nao	Real: Sim
Previsto: Nao	262	137
Previsto: Sim	74	175

```
VN = matriz["Nao", "Nao"]
FN = matriz["Nao", "Sim"]
FP = matriz["Sim", "Nao"]
VP = matriz["Sim", "Sim"]

metricas = tibble(
  Metrica = c(
    "Acurácia", "Sensibilidade", "Especificidade",
    "Precisão (VPP)", "Valor preditivo negativo",
    "Taxa de falsos positivos", "Taxa de falsos negativos"
  ),
  Valor = c(
    (VP + VN) / sum(matriz),
    VP / (VP + FN),
    VN / (VN + FP),
    VP / (VP + FP),
    VN / (VN + FN),
    FP / (FP + VN),
    FN / (FN + VP)
  )
) %>%
  mutate(Percentual = scales::percent(Valor, accuracy = 0.1))

kable(
  dplyr::select(metricas, Metrica, Percentual),
  caption = "Desempenho com ponto de corte = 0,50"
)
```

Table 24: Desempenho com ponto de corte = 0,50

Metrica	Percentual
Acurácia	67.4%
Sensibilidade	56.1%
Especificidade	78.0%
Precisão (VPP)	70.3%
Valor preditivo negativo	65.7%
Taxa de falsos positivos	22.0%
Taxa de falsos negativos	43.9%

```
roc_obj = roc(
  response = dados_teste[[variavel_resposta]],
  predictor = dados_teste$p_ocorrencia,
  levels = c("Nao", "Sim"),
  direction = "<",
  quiet = TRUE
```

```
)

auc_valor = as.numeric(auc(roc_obj))

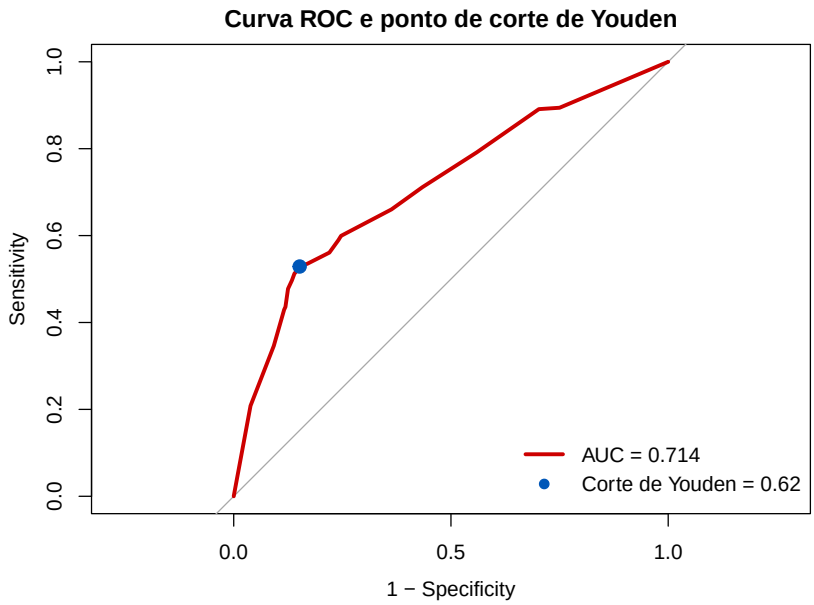
melhor_youden = coords(
  roc_obj,
  x = "best",
  best.method = "youden",
  ret = c("threshold", "sensitivity", "specificity"),
  transpose = FALSE
)

gini = 2 * auc_valor - 1

plot(
  roc_obj,
  legacy.axes = TRUE,
  col = "red3",
  lwd = 3,
  main = "Curva ROC e ponto de corte de Youden"
)

points(
  x = melhor_youden$specificity,
  y = melhor_youden$sensitivity,
  col = "#0057B8",
  pch = 19,
  cex = 1.4
)

legend(
  "bottomright",
  legend = c(
    paste0("AUC = ", round(auc_valor, 3)),
    paste0("Corte de Youden = ", round(melhor_youden$threshold, 3))
  ),
  col = c("red3", "#0057B8"),
  lwd = c(3, NA),
  pch = c(NA, 19),
  bty = "n"
)
```




```
kable(melhor_youden, digits = 3, caption = "Ponto de corte de Youden")
```

Table 25: Ponto de corte de Youden

threshold	sensitivity	specificity
0.62	0.529	0.848

O modelo tem AUC de 0,714 e índice de Gini de 0,428 no teste. Ele discrimina de forma razoável, mas quase só por causa do setor. O curso não entra no modelo final.

Conclusão da H1. Sem controles, cada curso concluído multiplica a chance de usar IA por 1,37 ($p < 0{,}001$). Com setor, senioridade, tempo de casa e licenças, a razão de chances cai para 1,04 ($p = 0{,}642$), e o intervalo de 95% passa a incluir 1. Já o setor tem efeito forte (p do `drop1` menor que 0,001). Ou seja, a associação do D1 vinha do setor: as empresas de tecnologia treinam mais e também usam mais IA. **Controlando pelo setor, H1 não se confirma.**

H2: treinamento reduz incidentes de segurança?

A resposta agora é `teve_incidente`. Incluímos também `log_req`, porque quem usa mais IA tem mais exposição a eventos de segurança.

```
variavel_resposta = "teve_incidente"

variaveis_quanti_h2 = c("cursos", "log_req", "licencas", "tempo_casa")

tabela_distribuicao_h2 = dados_colab %>%
  count(.data[[variavel_resposta]], name = "Frequencia") %>%
  mutate(Proporcao = Frequencia / sum(Frequencia)) %>%
  rename(Categoria = all_of(variavel_resposta))

kable(
  tabela_distribuicao_h2,
  digits = 3,
```

```
  caption = "Distribuição da variável resposta na amostra geral"
)
```

Table 26: Distribuição da variável resposta na amostra geral

Categoria	Frequencia	Proporcao
Nao	2094	0.97
Sim	64	0.03

Os incidentes são raros, então o corte de 0,50 não serve aqui: o modelo preveria “Nao” para quase todo mundo. Por isso olhamos direto a curva ROC e a AUC.

```
set.seed(2026)

dados_treino_h2 = dados_colab %>%
  group_by(.data[[variavel_resposta]]) %>%
  slice_sample(prop = 0.70) %>%
  ungroup()

dados_teste_h2 = dados_colab %>%
  anti_join(
    dados_treino_h2 %>% select(all_of(variavel_id)),
    by = variavel_id
  )

bind_rows(
  distribuicao_por_amostra(dados_treino_h2, "Treino"),
  distribuicao_por_amostra(dados_teste_h2, "Teste")
) %>%
  kable(digits = 3, caption = "Distribuição por amostra")
```

Table 27: Distribuição por amostra

Categoria	Frequencia	Amostra	Proporcao
Nao	1465	Treino	0.971
Sim	44	Treino	0.029
Nao	629	Teste	0.969
Sim	20	Teste	0.031

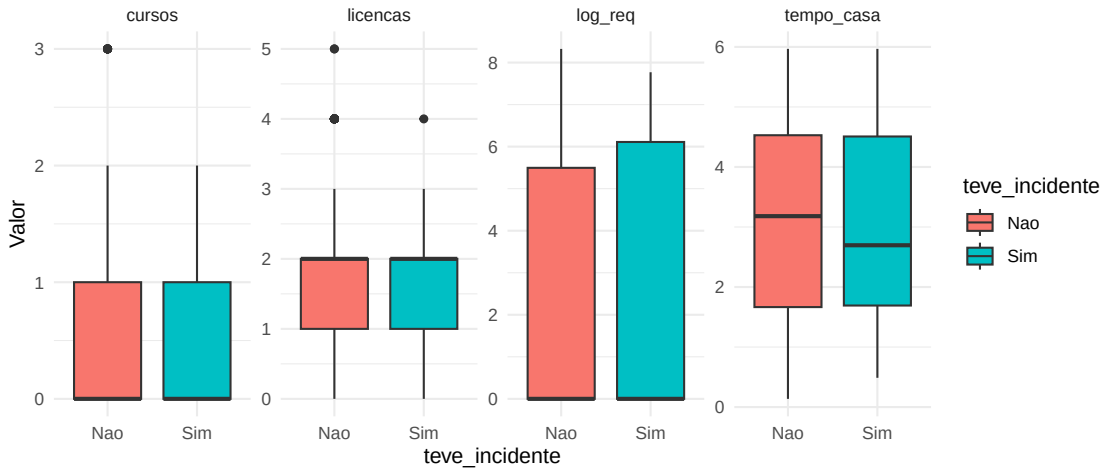
```
dados_treino_h2 = dados_treino_h2 %>%
  mutate(
    across(
      all_of(variaveis_quali),
      ~ relevel(
        factor(.x),
        ref = categorias_referencia[[cur_column()]]
      )
    ),
    "{variavel_resposta}" := factor(
      .data[[variavel_resposta]],
      levels = c("Nao", "Sim")
```

```
    )
  )

dados_teste_h2 = dados_teste_h2 %>%
  mutate(
    across(
      all_of(variaveis_quali),
      ~ factor(
        .x,
        levels = levels(
          dados_treino_h2[[cur_column()]]
        )
      )
    ),
    "{variavel_resposta}" := factor(
      .data[[variavel_resposta]],
      levels = levels(
        dados_treino_h2[[variavel_resposta]]
      )
    )
  )
```

```
dados_quanti_h2 = dados_treino_h2 %>%
  select(all_of(c(variavel_resposta, variaveis_quanti_h2))) %>%
  pivot_longer(
    cols = all_of(variaveis_quanti_h2),
    names_to = "Variavel",
    values_to = "Valor"
  )

ggplot(dados_quanti_h2,
       aes(x = .data[[variavel_resposta]], y = Valor,
           fill = .data[[variavel_resposta]])) +
  geom_boxplot() +
  facet_wrap(~ Variavel, scales = "free_y", nrow = 1) +
  theme_minimal()
```



Modelos

Assim como na H1, nenhum GVIF ajustado passa de 2,24.

```
modelo_simples_h2 = glm(
  teve_incidente ~ cursos,
  data = dados_treino_h2,
  family = binomial(link = "logit")
)

formula_modelo_h2 = reformulate(
  termlabels = c(variaveis_quanti_h2, variaveis_quali),
  response = variavel_resposta
)

modelo1_h2 = glm(
  formula = formula_modelo_h2,
  data = dados_treino_h2,
  family = binomial(link = "logit")
)

kable(
  tabela_coeficientes(modelo1_h2),
  caption = "Modelo logístico preliminar (H2)"
)
```

Table 28: Modelo logístico preliminar (H2)

Termo	Estimativa	Erro_padrao	Estatistica_z	Valor_p
(Intercept)	-3.146	0.609	-5.168	<0.001
cursos	-0.213	0.253	-0.841	0.4005
log_req	-0.026	0.062	-0.418	0.6759
licencas	0.017	0.200	0.087	0.9311
tempo_casa	0.026	0.093	0.283	0.7774
senioridadeEspecialista	-1.807	1.038	-1.741	0.0818
senioridadeGerente	0.280	0.578	0.485	0.6277
senioridadePleno	-0.815	0.388	-2.099	0.0358
senioridadeSenior	-0.549	0.418	-1.314	0.1889
setorFinanceiro	-0.169	0.524	-0.323	0.7465
setorMarketing	1.202	0.597	2.013	0.0441
setorServicos	1.298	0.577	2.249	0.0245
setorTecnologia	0.063	0.532	0.119	0.9055
setorVarejo	-0.457	0.578	-0.792	0.4286

```
resultado_gvif_h2 = car::vif(modelo1_h2)

tabela_gvif_h2 = resultado_gvif_h2 %>%
  as.data.frame() %>%
  rownames_to_column("Termo") %>%
  rename(
    Graus_liberdade = Df,
    GVIF_ajustado = `GVIF^(1/(2*Df))`
  )
```

```r
kable(
  tabela_gvif_h2,
  digits = 3,
  col.names = c("Termo", "GVIF", "Graus de liberdade", "GVIF ajustado"),
  caption = "Fatores generalizados de inflação da variância (H2)"
)
```

Table 29: Fatores generalizados de inflação da variância (H2)

Termo	GVIF	Graus de liberdade	GVIF ajustado
cursos	1.059	1	1.029
log_req	1.409	1	1.187
licencas	1.105	1	1.051
tempo_casa	1.024	1	1.012
senioridade	1.051	4	1.006
setor	1.652	5	1.051

```r
tabela_h2 = bind_rows(
  or_cursos(modelo_simples_h2, "Sem controles"),
  or_cursos(modelo1_h2, "Com controles")
)

kable(
  tabela_h2 %>%
    mutate(Valor_p = format.pval(Valor_p, digits = 3, eps = 0.001)),
  digits = 3,
  caption = "H2: razão de chances de ter incidente por curso concluído"
)
```

Table 30: H2: razão de chances de ter incidente por curso concluído

Modelo	OR	IC_95_inferior	IC_95_superior	Valor_p
Sem controles	0.894	0.552	1.447	0.648
Com controles	0.808	0.492	1.328	0.401

```r
drop1(modelo1_h2, test = "Chisq")
```

```
## Single term deletions
##
## Model:
## teve_incidente ~ cursos + log_req + licencas + tempo_casa + senioridade +
##     setor
##             Df Deviance    AIC     LRT Pr(>Chi)
## <none>           375.43 403.43
## cursos       1   376.18 402.18  0.7484  0.38698
## log_req      1   375.60 401.60  0.1749  0.67580
## licencas     1   375.44 401.44  0.0075  0.93105
## tempo_casa   1   375.51 401.51  0.0800  0.77735
## senioridade  4   384.65 404.65  9.2159  0.05592 .
## setor        5   387.92 405.92 12.4907  0.02865 *
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```r
modelo_aic_h2 = step(modelo1_h2, direction = "backward", trace = 0)

formula(modelo_aic_h2)
```

```
## teve_incidente ~ senioridade + setor
```

Desempenho na amostra de teste

```r
dados_teste_h2 = dados_teste_h2 %>%
  mutate(
    p_ocorrencia = predict(
      modelo_aic_h2,
      newdata = dados_teste_h2,
      type = "response"
    )
  )

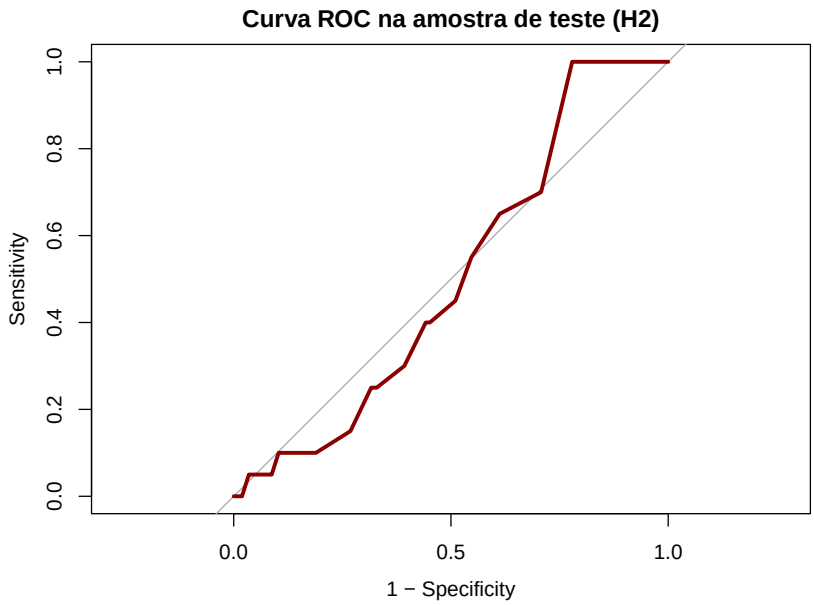
summary(dados_teste_h2$p_ocorrencia)
```

```
##     Min.  1st Qu.   Median     Mean  3rd Qu.     Max.
## 0.004616 0.015995 0.022868 0.029060 0.038171 0.123067
```

```r
roc_obj_h2 = roc(
  response = dados_teste_h2[[variavel_resposta]],
  predictor = dados_teste_h2$p_ocorrencia,
  levels = c("Nao", "Sim"),
  direction = "<",
  quiet = TRUE
)

auc_valor_h2 = as.numeric(auc(roc_obj_h2))
gini_h2 = 2 * auc_valor_h2 - 1

plot(
  roc_obj_h2,
  legacy.axes = TRUE,
  col = "red4",
  lwd = 3,
  main = "Curva ROC na amostra de teste (H2)"
)
```



A AUC é de 0,503, quase a de um sorteio (0,5), e o Gini é de 0,005. O modelo não consegue prever quem terá incidente.

Conclusão da H2. A razão de chances por curso é de 0,81 com controles, e o intervalo de 95% (0,49 a 1,33) inclui 1 (p = 0,401). O AIC também tira `cursos` do modelo. **H2 continua não confirmada.**

Resultados e interpretação

1. **Os indicadores se resumem em três dimensões:** uso, capacitação e investimento. Dos 14 indicadores iniciais, 3 saíram por quase não terem correlação com os demais. Investimento é a dimensão menos consistente.
2. **Incidentes não acompanham as outras dimensões.** O risco de segurança não é explicado por quanto o departamento usa, treina ou gasta, então precisa de indicador próprio.
3. **O setor pesa muito na maturidade.** Tecnologia lidera o IMIA. A Indústria fica por último (25,6), mas tem o segundo maior IINV (52,2). A regressão confirma isso no nível do colaborador: o setor é a única variável com efeito forte sobre o uso.
4. **23 departamentos estão no quadrante de desperdício**, com investimento acima da mediana e maturidade abaixo dela. São o primeiro alvo da realocação de licenças.
5. **Encontramos três perfis de departamento:** avançados, capacitados com investimento baixo e adoção baixa. Os métodos concordam entre si, mas a silhueta baixa mostra que os grupos não são muito separados. O grupo de adoção baixa é o maior (54 departamentos). Nele, 71% das licenças ficam paradas, contra 22% nos avançados.
6. **16 departamentos usam IA acima da média com capacitação abaixo da média.** São o público natural dos níveis de autonomia do DAMA.
7. **H1 não se sustenta com controles.** A associação do D1 vinha do setor.
8. **H2 continua não confirmada.**

O que isso muda no DAMA

- O painel pode mostrar três indicadores-síntese (uso, capacitação e investimento), com os 11 indicadores como detalhamento.
- Licenças ociosas são o sinal mais fácil de corrigir e ligam esta análise ao modelo de otimização de licenças.

- Nos dados, treinamento sozinho não aparece ligado a mais uso nem a menos incidentes. A sugestão é que ele venha junto de acesso às ferramentas certas e metas de uso.

  A regressão logística identifica associações. Sozinha, ela não demonstra que uma característica causa o uso de IA ou os incidentes.

Limitações

- A base é sintética, e o orçamento foi gerado de forma independente do gasto, o que influencia `execucao`.
- A H1 aqui mede se o colaborador usa IA ou não, e não quanto ele usa.
- Os incidentes são raros (64 colaboradores), o que limita os testes da H2.
- Os indicadores são médias do período, então não dá para ver se o curso veio antes do aumento de uso.
- O IMIA dá peso igual a uso e capacitação. Foi uma escolha simples, e outros pesos mudariam um pouco o ranking.

Exportação dos resultados

```
write_xlsx(
  list(
    Dados_segmentados = dados_segmentados,
    Ranking = ranking,
    Indices_empresas = indice_empresas,
    Perfil_original = perfil_original,
    Perfil_padronizado = perfil_padronizado,
    Avaliacao_k = avaliacao_k
  ),
  path = "segmentacao_departamentos.xlsx"
)
```

O trecho está com `eval=FALSE` para não criar o arquivo toda vez que compilar. Para exportar, execute o bloco manualmente.